


Segmentacja obrazów dna oka

IwM - projekt 2

Obrazy dna oka

- Jedno z podstawowych okulistycznych badań obrazowych
- Wykorzystywane w skriningu (screening) i diagnostyce
- Łatwe do realizacji -- niewielkie gabaryty i cena sprzętu



[Do it yourself smartphone fundus camera – DIYretCAM](#)

Problem do rozwiązania


Segmentacja (wykrycie) naczyń krwionośnych na obrazie dna oka

- Binarna klasyfikacja punktu obrazu na podstawie jego otoczenia (*patch*)
 - Naczynie
 - Tło (nie-naczynie)
- Znacznie mniejsze wymagania dotyczące danych (wiele przykładów uczących i testowych otrzymanych z jednego obrazu)
- Niezrównoważenie klas -- naczyń jest znacznie mniej na obrazie niż tła


Dostępne zdjęcia

HRF Image Database (<https://www5.cs.fau.de/research/data/fundus-images/>)


Właściwe zdjęcie



Maska ekspercka -- gold standard




Field of view (FOV)



Wartość “informacyjna” kolorów

Red



Green



Blue




Przetwarzanie obrazu

- Wykorzystanie “tradycyjnych” technik niewymagających uczenia
- Przykład: filtr Frangi’ego (`skimage.filters.frangi`)
 - Uwaga na “ramkę” wokół obrazu
 - Konieczne progowanie w celu uzyskania finalnej maski
- Wyznaczenie podstawowych metryk oceniających działanie filtra
 - Porównanie uzyskanej maski z maską ekspercką
 - Wykorzystanie `sklearn.metrics` oraz `imblearn.metrics`
 - Uwaga na właściwie kodowanie obu masek (1 i 255)



Tradycyjne uczenie maszynowe

Przygotowanie przykładów na podstawie “wycinków” obrazu i przesuwanego okna



Tradycyjne uczenie maszynowe

- Podział przykładów na uczące i testujące
 - Wykorzystanie różnych obrazów
 - Podział (**warstwowy** → stratified) w ramach obrazu, np. 2/3 : 1/3 --
`sklearn.model_selection.train_test_split`
- Możliwe wstępne przetwarzanie zbioru **uczącego** w celu wyrównania niezerównoważenia klas, np. do 0.5:0.5 albo 0.4:0.6
 - Dobre efekty dla prostego undersamplingu (`imblearn.under_sampling.RandomUndersampler`)
 - Dostępne bardziej zaawansowane metody (również w `imbalanced-learn`)


Tradycyjne uczenie maszynowe

- Uczenie klasyfikatora i optymalizacja wybranych hiper-parametrów
 - Przeszukiwanie przestrzeni hiper-parametrów: `sklearn.model_selection.GridSearchCV` lub `RandomizedSearchCV`
 - Dla chętnych i odważnych :) -- auto-sklearn ([auto-sklearn — AutoSklearn 2.0 documentation](#)), Linux albo WSL!
- Testowanie klasyfikatora i zastosowanie do nowych obiektów -- przekazanie możliwie dużego zbioru obiektów do metody `Classifier.predict`
- Wykorzystanie `pipelines` (sklearn, imblearn) w celu uproszczenia kodu -- “z automatu” poprawne przetwarzanie zbioru uczącego i testowego

Przykład działania klasyfikatora


Uwaga -- tutaj zastosowano skok > 1 podczas przetwarzania punktów obrazu testowego

Wykorzystany klasyfikator to *random forest*



Uczenie głębokie

- Uczenie na “wycinkach” obrazu, jak poprzednio, jednak bez konieczności ręcznej konstrukcji cech (również wyrównanie rozkładu klas)
- Wykorzystanie sieci U-Net -- segmentacja całego (przeskalowanego) obrazu lub jego dużych fragmentów
- Uwaga na możliwą konieczność przeskalowania / dopasowania maski Eksperckiej
- Przykładowa implementacja:
<https://github.com/milesial/pytorch-unet>



<https://lmb.informatik.uni-freiburg.de/people/ronneber/u-net/>

Pozostałe wymagania

[DnoOka](#)